

ТЗ кейса для HackAlem AI

Направление: Аналитика и принятие решений / Кибербезопасность и комплаенс

Формат: командная разработка, 5 часов

Данные: предоставляются в начале хакатона, обезличенные

1. Название

Граф денег: восстановление финансовой структуры организованной группы по транзакционной сети

2. Проблема

Сейчас AML-аналитик банка второго уровня сталкивается с тем, что по итогам оперативной информации ему известен только **нижний уровень** преступной цепочки — конкретные клиенты, получавшие деньги, связанные с незаконным оборотом наркотиков. Кто стоит выше — кто собирает эти деньги, через кого их прогоняют и кто в итоге ими распоряжается — приходится восстанавливать вручную.

Из-за чего:

Последствие	Масштаб
Ручная трассировка цепочки от одного клиента на 4 колена	часы работы аналитика на один узел
Основная часть сети остаётся невидимой	известен 81 клиент, реальная сеть — 2 248 узлов
Блокируется только нижний уровень	организаторы сохраняют инфраструктуру и восстанавливают её за дни
Решения о приоритете проверки принимаются интуитивно	нет ранжирования, кого смотреть первым

Эффект от решения: аналитик за минуты получает ранжированный список узлов с обоснованием роли каждого, вместо недель ручной трассировки; фокус проверки смещается с 81 «курьера» на реальные точки консолидации.

3. Пользователь

Основной пользователь: AML-аналитик / специалист подразделения финансового мониторинга банка второго уровня.

Ключевой сценарий (от входа до результата):

1. Аналитик получает от правоохранительных органов список клиентов, проходящих по делу (81 gid).
2. Загружает выгрузку исходящих переводов этих клиентов на 4 колена в инструмент команды.
3. Инструмент строит граф, считает метрики и **присваивает каждому узлу роль:** точка консолидации, транзит, распределитель, конечный получатель, периферия.

- Аналитик видит схему сети с направлением потоков, подсветкой ролей и кластерами.
- Аналитик открывает **топ-лист приоритетов**, читает обоснование по каждому узлу («получает от 11 разных плательщиков, отдаёт дальше 3% полученного») и формирует перечень клиентов на углублённую проверку и запрос в правоохранительные органы.

4. Задача

Разработать **аналитический инструмент (пайплайн + интерфейс просмотра)**, который по графу транзакций определяет роли участников финансовой сети и ранжирует их по значимости, и выдаёт аналитику готовую к работе модель структуры группы: участники, связи, направление денег, транзитные узлы, точки консолидации, кластеры, ключевые узлы.

Инструмент должен отвечать на вопрос аналитика: **«кого из этих 2 248 клиентов смотреть первым и почему»**.

5. Вход → выход

Вход

Параметр	Значение
Формат	3 файла .parquet (edges, nodes, transactions)
Объём	2 248 узлов, 3 119 рёбер, 4 840 транзакций
Период	2026-07-01 — 2026-07-31
Частота	разовая выгрузка (батч), онлайн-поток не требуется
Пример	предоставляется полный датасет, схема полей — в README.md датасета

Выход

Три CSV-выгрузки фиксированной схемы + экран просмотра.

`nodes_roles.csv` — строка на каждый из 2 248 узлов:

Колонка	Тип	Смысл
<code>gid</code>	<code>int64</code>	идентификатор клиента
<code>role</code>	<code>str</code>	основная роль из словаря (см. ниже)
<code>role_score</code>	<code>float</code>	уверенность в роли, 0–1
<code>cluster_id</code>	<code>int</code>	номер кластера
<code>priority_score</code>	<code>float</code>	приоритет для аналитика, 0–1
<code>evidence</code>	<code>str</code>	почему присвоена роль — до 200 символов, человекочитаемо

Словарь ролей (обязательный минимум; команда может расширить, задокументировав):

Роль	Смысл
consolidator	точка консолидации — аккумулирует средства от нескольких участников
transit	транзитный счёт — пропускает средства дальше, не удерживая
distributor	веерное распределение средств на много получателей
terminal	конечный получатель — деньги приходят и остаются
coordinator	координирующий узел, кандидат в организаторы
peripheral	периферия, признаков роли не выявлено

clusters.csv — строка на кластер: cluster_id, n_nodes, n_seed, sum_kzt_internal, top_gids, hypothesis (гипотеза о назначении кластера).

top_nodes.csv — ранжированный список **не менее 20** узлов: rank, gid, role, priority_score, why (обоснование текстом).

Экран просмотра: схема сети с направлением потоков, подсветкой ролей/кластеров и поиском по gid. Веб-страница, ноутбук или desktop — на усмотрение команды.

Допустимая задержка: полный пересчёт от сырых .parquet до выгрузок — **не более 5 минут** на предоставленном объёме.

6. Данные

Способ доступа: архив с папкой data/ выдаётся всем командам в начале хакатона. Внешние источники не требуются и не предполагаются.

Состав

Файл	Строк	Содержание
edges.parquet	3119	пара плательщик→получатель, агрегированная за период: src, dst, sum_kzt, n_tx, depth
nodes.parquet	2248	уникальный клиент: gid, depth (минимальное колено), is_seed
transactions.parquet	4840	отдельная транзакция: src, dst, date, sum_kzt

Полное описание полей — в README.md датасета.

Как собран граф

- стартовые вершины — 81 клиент, ранее выявленный как участник незаконного оборота наркотиков;
- прослеживаются **только исходящие** переводы, глубина обхода — **4 колена**;
- порог: транзакции < 5 000 KZT **не попали в выгрузку**;
- только внутрибанковские переводы, июль 2026.

Распределение по коленам: seed — 81, 1-е — 472, 2-е — 462, 3-е — 789, 4-е — 444.
Суммарный оборот в графе: **365 890 012 KZT**.

Качество и ограничения данных (объявлены заранее — их учёт оценивается)

Особенность	Что это значит для решения
Обрыв на 4-м колене. 444 узла имеют depth=4 и нулевые исходящие — это артефакт обхода, а не «деньги осели»	наивный признак «out_degree = 0 ⇒ конечный получатель» даст 444 ложных «сток»
Только исходящие переводы. Входящие потоки на узлы за пределами выборки не видны	нельзя достоверно считать полный баланс узла
У seed-клиентов входящие суммы занижены — граф собран <i>от</i> них, деньги, полученные ими извне выборки, в данные не попали	отношение «отдал / получил» у seed некорректно; 354 узла графа отдают больше, чем по данным получили
Порог 5 000 KZT	дробление ниже порога в данных невидимо
19 из 81 seed отсутствуют в рёбрах, ещё 12 присутствуют только как получатели	31 seed не имеет исходящих переводов — учитывать при обходе
16 слабосвязных компонент: 1 877 узлов (46 seed), 270 (1 seed), остальные 14 — от 2 до 17 узлов	сеть не монолитна, 352 узла вне крупнейшей компоненты
Нет атрибутов клиента — ни ФИО, ни возраста, ни типа операции, ни остатков	только структура и суммы
Нет размеченных ролей (ground truth)	оценка — по обоснованности критериев, а не по accuracy

Лицензия и приватность: данные обезличены (gid — синтетический идентификатор без привязки к личности), предоставляются исключительно для использования в рамках хакатона.

7. Must have

Без этих пяти пунктов решение не считается выполненным. К каждому — способ проверки.

№	Обязательная функция	Как проверяется
1	Воспроизводимый пайплайн. Один запуск от сырых .parquet до всех трёх выгрузок, без ручных шагов	Жюри запускает команду из README на чистой машине; пайплайн отрабатывает < 5 минут и создаёт 3 файла
2	Роль и скор у каждого узла. Все 2 248 узлов получили роль из словаря, role_score и evidence	nodes_roles.csv содержит 2 248 строк, все обязательные колонки заполнены, evidence непустой

№	Обязательная функция	Как проверяется
3	Критерии ролей задокументированы и объяснимы. Для каждой роли — формальное правило или метрика с порогом	Жюри называет 3 произвольных gid; команда за минуту объясняет, почему роль именно такая, опираясь на свои метрики
4	Кластеризация сети. Узлы разбиты на группы, по каждому кластеру — размер, число seed, оборот и гипотеза	clusters.csv заполнен; cluster_id есть у каждого узла в nodes_roles.csv
5	Топ-лист приоритетов + визуализация. Ранжированный список ≥ 20 узлов с обоснованием и экран со схемой сети, где видно направление потоков и роли	top_nodes.csv заполнен; на демо жюри называет gid — команда находит его на схеме и показывает его связи

8. Опционально

Дают дополнительные баллы, сдачу не блокируют:

- **Учёт артефакта обрыва графа** — отделение настоящих конечных получателей от узлов, «обрезанных» 4-м коленом, с обоснованием метода.
- **Временные паттерны** — сквозной транзит (пришло и ушло в течение 1–2 дней), всплески активности, синхронные переводы от нескольких плательщиков в один день.
- **Поиск повторяющихся маршрутов и возвратных потоков** — устойчивые цепочки $A \rightarrow B \rightarrow C$ и циклы, где деньги возвращаются к отправителю.
- **Детекция аномалий** — дробление сумм, аномальные профили узлов относительно их колена (правила или ML-модель).
- **Оценка устойчивости сети** — что произойдёт с сетью при изъятии топ-N узлов; распадается ли она на изолированные фрагменты.
- **AI-ассистент аналитика** — вопрос на естественном языке («кто собирает деньги с этих пятерых?») → ответ по графу со ссылками на узлы.
- **Автогенерация карточки узла** — краткая справка по клиенту: роль, потоки, связи, на что обратить внимание.
- **Оценка полноты** — указание, каких данных не хватает, чтобы закрыть белые пятна, и какой запрос аналитику стоит сделать следующим.

9. Ограничения

Нельзя

- **Хардкодить результат** — зашитые в код списки gid под «правильный ответ» вместо расчёта.
- **Сдавать «чёрный ящик»** — роль без объяснимого правила или интерпретируемых признаков не засчитывается (см. must have 3).
- **Обогащать внешними источниками** и достраивать атрибуты клиентов, которых нет в данных (пол, возраст, доход, организация) — любые такие поля будут считаться выдумкой.

- **Требовать облачный кластер, GPU-обучение или платные сервисы** для воспроизведения результата.

Обязательно учесть

Требование	Что это значит
Explainability	каждая роль и каждая позиция в топ-листе сопровождается обоснованием, понятным аналитику без ML-образования
Приватность	данные обезличены; решение не должно предполагать работу с ФИО, ИИН или иными персональными данными
Осторожность формулировок	выводы формулируются как гипотезы для проверки («признаки консолидации»), а не как утверждение о виновности
Производительность	полный пересчёт ≤ 5 минут на предоставленном объёме, локально, на обычном ноутбуке
Инфраструктура	всё работает локально; интернет может потребоваться только для внешнего LLM API, если команда его использует
Стек	любой язык и библиотеки; рекомендуется Python (pandas, networkx/igraph) — стартовый код предоставляется
Масштабируемость	в README указать, что изменится в подходе при росте графа до ~1 млн узлов (текстом, реализация не требуется)

10. Артефакты

Артефакт	Обязателен	Содержание
Репозиторий	да	исходный код пайплайна и интерфейса
README	да	как запустить (одна команда), описание критериев ролей и порогов, что на выходе, ограничения подхода, раздел про масштабирование
Выгрузки	да	nodes_roles.csv, clusters.csv, top_nodes.csv
Схема решения	да	один слайд/диаграмма: данные → метрики → роли → интерфейс
Демо	да	5 минут: живой прогон и разбор 2–3 узлов по существу

Стартовый код (загрузка данных, сборка графа, базовые метрики, шаблоны выгрузок) предоставляется организаторами в папке `starter/` — чтобы команды не тратили час из пяти на boilerplate.

Примечание для организаторов

Кейс проверен на данных: заявленные must-have выполнимы за 5 часов командой из 3–4 человек. В данных присутствуют выраженные кандидаты на все роли словаря — узлы с входящими переводами от 8–24 разных плательщиков, узлы с веерной рассылкой на 60–116 получателей, 72 узла с коэффициентом пропуска 0.8–1.2, а при базовой кластеризации (Louvain) — 8 устойчивых сообществ, содержащих более одного seed-клиента. Задача имеет решение, но не имеет единственного правильного ответа — это заложено намеренно, оценка идёт по обоснованности критериев.

Критерий	Что оцениваем	Баллы
Соответствие задаче и работоспособность	Оценивается, насколько решение соответствует поставленной задаче и позволяет реализовать основной заявленный сценарий.	25
Техническая реализация	Оценивается качество технической реализации решения: выбранный подход, архитектура, взаимодействие компонентов, использование AI/agent AI и других технологий. Учитывается соответствие фактической реализации заявленной логике проекта.	25
README и воспроизводимость	Оценивается, насколько документация позволяет понять устройство проекта, используемые технологии, порядок запуска и основной сценарий работы. Также учитывается возможность воспроизвести и проверить решение на основании материалов репозитория.	25
Ценность и применимость решения	Оценивается, насколько решение отвечает обозначенной проблеме. Учитывается практическая применимость представленного подхода.	15
Потенциал развития и оригинальность подхода	Оценивается потенциал дальнейшего развития решения, его применения в более широком масштабе, а также наличие обоснованных нестандартных или оригинальных подходов к реализации задачи.	10
Итого	—	100